

Desafio 15  
ME315-2S2025

**brotto**

2025-11-20

## Sumário

§ Natureza . . . . .	2
§ Resumo . . . . .	2
§ Introdução . . . . .	2
<b>Julia - loops em paralelo</b>	<b>2</b>

## § Natureza

Desafio 15

## § Resumo

Veremos a execução de um processo em paralelo no julia, bem como comparar com sua versão serial.

## § Introdução

Loops em paralelo por vezes ajudam a calcular operações de forma mais veloz. A seguir, estão resultados de uma análise de performance entre computação serial e paralela. O problema é a estimação de  $\pi$  através do método de monte carlo — um processo iterativo (utiliza loops).

## Julia - loops em paralelo

```
julia_setup(JULIA_HOME = NULL)

# Pkg
import Pkg

# status
Pkg.status()

## Status `C:\Users\User\.julia\environments\v1.12\Project.toml`
##  [6e4b80f9] BenchmarkTools v1.6.3
##  [429524aa] Optim v1.13.2
##  [91a5bcdd] Plots v1.41.1
##  [6f49c342] RCall v0.14.9
##  [10745b16] Statistics v1.11.1
##  [fd094767] Suppressor v0.2.8
##  [8ba89e20] Distributed v1.11.0
## Info Packages marked with   have new versions available and may be upgradable.

# baixa
using Pkg
Pkg.add("Distributed")
Pkg.add("Statistics")
Pkg.add("BenchmarkTools")

# carrega
```

```
using Distributed, Statistics, BenchmarkTools
```

```
# serial
function monte_carlo_serial(n)
    dentro = 0
    for i in 1:n
        x, y = rand(), rand()
        if x^2 + y^2 <= 1.0
            dentro += 1
        end
    end
    return 4.0 * dentro / n
end
```

```
## monte_carlo_serial (generic function with 1 method)
```

```
# @distributed
function monte_carlo_distributed(n)
    dentro = @distributed (+) for i in 1:n
        x, y = rand(), rand()
        Int(x^2 + y^2 <= 1.0)
    end
    return 4.0 * dentro / n
end
```

```
## monte_carlo_distributed (generic function with 1 method)
```

```
# testes
function teste_distributed()
    n = 10_000_000

    tempo_serial = @elapsed pi_serial = monte_carlo_serial(n)
    tempo_parallel = @elapsed pi_parallel = monte_carlo_distributed(n)

    speedup = tempo_serial / tempo_parallel

    erro_serial = abs(pi_serial - )
    erro_parallel = abs(pi_parallel - )

    diferenca = abs(erro_serial - erro_parallel)

    return pi_serial, pi_parallel, tempo_serial, tempo_parallel, speedup, diferenca,
        ↪ erro_serial
end
```

```
## teste_distributed (generic function with 1 method)
```

```
nprocs() # n de processos
```

```
## 1
```

```
JuliaCall:::julia$cmd("(nprocs() == 1) ? addprocs(3) : FALSE")
```

```
nprocs() # n de processos
```

```
## 4
```

```
# pi_serial, pi_parallel, tempo_serial, tempo_parallel, speedup, diferenca, erro_serial
resultado = teste_distributed() # testa
```

```
## (3.1415292, 3.1416568, 0.0446199, 2.8104146, 0.01587662546301887, 6.928204134837301e-
7, 6.345358979320537e-5)
```

Ganho em performance:

0.0158766x (o “ganho”na verdade é uma perda, já que  $\text{speedup} \leq 1x$ )

---

*## O resultado gerado pela compilação do knitr é mais lento, mas o tempo de compilação de  
↪ fato é mais veloz usando o processamento paralelo.*

```
(3.1416076, 3.1412776, 0.0422801, 0.0206611, 2.0463624879604665, 0.0003001071795862842, 1.4946410206828631e-5)
```

Figura 1: Saída indicando melhora de aprox. 2.04x no tempo de execução.

Notas:

```
## O @distributed com (+) faz automaticamente:
## 1. Divide o loop 1:n entre workers
## 2. Cada worker calcula sua soma parcial
## 3. Combina todas as somas parciais com +
dentro = @distributed (+) for i in 1:n
  # Retorna 1 ou 0 para cada ponto
  Int(rand()^2 + rand()^2 <= 1.0)
end
```