Leitura e Processamento de Dados em Lote

ME315-2S2025

Bruce Trevisan - RA277200 Guilherme Duarte Alves Basso - RA240805
Heitor Brotto Gomes e Silva - 260181 Rafael Gomes Carneiro - RA185462

2025-11-25

Sumário

§ Natureza

Este documento apresenta as soluções propostas para as seguintes atividades da disciplina ME315-2S2025:

- **Laboratório nº 2**, apresentado em aula no dia 14 de agosto de 2025;
- **Desafio nº 2**, que consiste na replicação do Laboratório 2 utilizando a linguagem **Python**;
- **Trabalho Final**, proposto em 21 de outubro de 2025, que estende a análise para a linguagem **Julia**.

§ Resumo

São apresentados, a seguir, exemplos de soluções para os problemas mencionados. O **Laboratório 2** consiste em um exercício originalmente elaborado por professores que ministraram a disciplina em semestres anteriores. O **Desafio 2** propõe a reprodução da mesma atividade utilizando a linguagem **Python**, enquanto o **Trabalho Final** expande a abordagem para a linguagem **Julia.**

§ Introdução

A atividade inicial, proposta pelos professores Benilton e Guilherme, tem como objetivo desenvolver habilidades essenciais para estatísticos, especialmente no que se refere à manipulação de conjuntos de dados, incluindo aqueles de grande volume. Com a inclusão das linguagens Python e Julia, o escopo do trabalho ampliou-se, abrangendo agora a comparação entre diferentes ferramentas computacionais.

Em virtude da integração de múltiplas atividades em um único documento, detalhes excessivos sobre cada solução nem sempre são apresentados ao longo do texto. Para uma compreensão mais aprofundada, recomenda-se a consulta ao código-fonte em **RMarkdown** utilizado para gerar este relatório.

Vale ressaltar que a compilação desse código depende da instalação de diversos pacotes e da configuração prévia dos ambientes **R**, **Python** e **Julia.** A instalação das dependências de R é tratada automaticamente pelo documento, porém, os interpretadores de Python e Julia devem estar previamente configurados. Além disso, o arquivo `columns.tex` deve estar presente no mesmo diretório do arquivo Rmd durante a compilação. Interessados em reproduzir ou modificar este relatório devem assegurar-se de atender a todos os requisitos listados.

Tabela 1: Os dois primeiros registros do CD.

YEAR	MONTH	DAY	DAY_OF_WEEK	AIRLINE	FLIGHT_NUMBER
2015	1	1	4	AS	98
2015	1	1	4	AA	2336

TAIL_NUMBER	ORIGIN_AIRPORT	DESTINATION_AIRPORT
N407AS	ANC	SEA
N3KUAA	LAX	PBI

SCHEDULED_DEPARTURE	DEPARTURE_TIME	DEPARTURE_DELAY	TAXI_OUT
0005	2354	-11	21
0010	0002	-8	12

WHEELS_OFF	SCHEDULED_TIME	ELAPSED_TIME	AIR_TIME	DISTANCE
0015	205	194	169	1448
0014	280	279	263	2330

WHEELS_ON	TAXI_IN	SCHEDULED_ARRIVAL	ARRIVAL_TIME	ARRIVAL_DELAY
0404	4	0430	0408	-22
0737	4	0750	0741	-9

DIVERTED	CANCELLED	CANCELLATION_REASON	AIR_SYSTEM_DELAY
0	0	NA	NA
0	0	NA	NA

SECURITY_DELAY	AIRLINE_DELAY	LATE_AIRCRAFT_DELAY	WEATHER_DELAY
NA	NA	NA	NA
NA	NA	NA	NA

§ Conjunto de dados (CD): `flights.csv.zip`

```
## Nome do arquivo com os dados
   file0 = "flights.csv.zip"
```

```
## Amostra do CD com os 2 primeiros registros
   a = readr::read_csv(file = file0, n_max = 2)
   lista_partes <- split.default(a, cut(1:ncol(a), breaks = seq(0, ncol(a), by = 1)))
```

```
## Trata e imprime Tabela 1
   latex = (lista_partes %>% my_kbl())[1]
   ss = substring(latex, 14, nchar(latex))
   s4 = " Colunas}"; s3 = "\\textit{ "; s2 = "\\caption{Os dois primeiros registros do
 ↪  CD.}"; s1 = "\\begin{table}"
   paste0(s1,s2,ss,s3,file.info(file0)$size * 1e-6," Mb | ",ncol(a),s4) %>% cat()
```

200.91153 Mb | 31 Colunas

Julia

```
## Captura do tempo inicial para monitoramento de performance
   t0 = Sys.time()
## Configurando o ambiente em Julia
   julia_setup(JULIA_HOME = NULL)
   julia_assign("file0",file0)
```

```
# Instalação de pacotes
import Pkg

# Verifica se o ambiente já existe e está atualizado
function setup_environment()
    env_path = "temp.venv"

    if isdir(env_path)
        println("Ambiente Julia já existe. Verificando pacotes...")
        Pkg.activate(env_path)

        # Lista de pacotes necessários
        required_pkgs = ["CSV", "DataFrames", "Dates", "Statistics", "ZipFile", "Plots"]
        installed_pkgs = keys(Pkg.project().dependencies)

        # Encontra pacotes faltantes
        missing_pkgs = setdiff(required_pkgs, installed_pkgs)

        if !isempty(missing_pkgs)
            println("Instalando pacotes faltantes: ", missing_pkgs)
            Pkg.add(collect(missing_pkgs))
        else
            println("Todos os pacotes já estão instalados.")
        end
    else
        println("Criando novo ambiente Julia...")
        Pkg.activate(env_path, shared = true)
        Pkg.add(["CSV", "DataFrames", "Dates", "Statistics", "ZipFile", "Plots"])
    end
end
```

```
## setup_environment (generic function with 1 method)
```

```
# Executa setup
setup_environment()
```

```
## Criando novo ambiente Julia...
```

```
# Carrega pacotes
using CSV, DataFrames, Dates, ZipFile, Statistics, Plots
```

```
function getStats(chunk::DataFrame)::DataFrame

    # Filtra companhias aéreas de interesse
    major_airlines = ("AA", "DL", "UA", "US")
```

```
    filtered = filter(row -> row.AIRLINE in major_airlines, chunk)

    # Remove valores missing no atraso de chegada
    filtered = filter(row -> !ismissing(row.ARRIVAL_DELAY), filtered)

    # Calcula se o voo está atrasado (>10 minutos)
    filtered[!, :late] = filtered.ARRIVAL_DELAY .> 10

    return filtered
end
```

```
## getStats (generic function with 1 method)
```

```
function computeStats(processed_data)

    # Cria coluna de data
    processed_data[!, :Date] = Date.(
        string.(processed_data.YEAR, "-",
               lpad.(string.(processed_data.MONTH), 2, "0"), "-",
               lpad.(string.(processed_data.DAY), 2, "0"))
    )
    # Agrupa por companhia e data para calcular estatísticas
    gdf = groupby(processed_data, [:AIRLINE, :Date])
    result = combine(gdf) do group
        total_flights = nrow(group)
        delayed_flights = sum(group.late)
        perc_delayed = delayed_flights / total_flights
        return (Perc = perc_delayed,)
    end

    return result
end
```

```
## computeStats (generic function with 1 method)
```

```
function plot_calendar_heatmap(stats, airline_code)
    airline_data = filter(row -> row.AIRLINE == airline_code, stats)

    # Prepara dados para heatmap mensal
    months = 1:12
    p = plot(layout = (4, 3), size = (800, 600))

    for (i, month) in enumerate(months)
        month_data = filter(row -> month == Dates.month(row.Date), airline_data)

        if nrow(month_data) > 0
            heatmap_data = zeros(7, 5)  # 7 dias da semana, 5 semanas máximas

            for row in eachrow(month_data)
                day_of_week = Dates.dayofweek(row.Date)
                week_of_month = ceil(Int, Dates.day(row.Date) / 7)
                heatmap_data[day_of_week, week_of_month] = row.Perc
            end
```

```
            # Paleta customizada - branco para 0, gradiente para valores > 0
            custom_palette = cgrad([
                RGB(1.0, 1.0, 1.0),    # Branco puro para 0
                RGB(0.69, 0.85, 0.90), # Azul muito claro
                RGB(0.49, 0.75, 0.93), # Azul claro
                RGB(0.27, 0.46, 0.71), # Azul médio (#4575b4)
                RGB(0.18, 0.20, 0.28)  # (#473027)
            ])

            color_limits = (0.0, maximum(heatmap_data) > 0 ? maximum(heatmap_data) : 0.1)

            heatmap!(subplot = i, heatmap_data,
                    title = Dates.monthname(month),
                    color = custom_palette,
                    clims = color_limits,
                    xticks = false,        # Remove ticks do eixo X
                    yticks = (1:7, ["Dom", "Seg", "Ter", "Qua", "Qui", "Sex", "Sáb"]))
        end
    end
    return p
end
```

```
## plot_calendar_heatmap (generic function with 1 method)
```

```
function computeMoreStats(stats)
    # Primeiro, filtra apenas as companhias de interesse
    stats_filtrado = filter(row -> row.AIRLINE in ["AA", "DL", "UA", "US"], stats)

    # Agrupa e calcula estatísticas
    return combine(
        groupby(stats_filtrado, :AIRLINE),
        :Perc => (x -> round(mean(x) * 100, digits=2)) => :Atraso_Medio,
        :Perc => (x -> round(maximum(x) * 100, digits=2)) => :Atraso_Maximo
    )
end
```

```
## computeMoreStats (generic function with 1 method)
```

```
# Especificação de tipos para leitura mais rápida
types_dict = Dict(
    :DAY => Int32,
    :MONTH => Int32,
    :YEAR => Int32,
    :AIRLINE => String,
    :ARRIVAL_DELAY => Union{Int32, Missing}
);

# Leitura apenas das colunas necessárias
selected_cols = ["DAY", "MONTH", "YEAR", "AIRLINE", "ARRIVAL_DELAY"];

# z
vetor_dataframes = [];
zip_archive = ZipFile.Reader(file0);
try
```

```
    csv_file = zip_archive.files[1]
    chunks = CSV.Chunks(csv_file, select = selected_cols, types = types_dict, ntasks = 5)
    for (i,chunk) in enumerate(chunks)
        df_chunk = DataFrame(chunk)
        println("Processando chunk #$i (#$(nrow(df_chunk)) linhas)")
        push!(vetor_dataframes, getStats(df_chunk))
    end
finally
    close(zip_archive)
end
```

```
## Processando chunk #1 (#1175972 linhas)
## Processando chunk #2 (#1169190 linhas)
## Processando chunk #3 (#1168127 linhas)
## Processando chunk #4 (#1155813 linhas)
## Processando chunk #5 (#1149977 linhas)
```

```
# Agregando resultados
df_final = reduce(vcat, vetor_dataframes);

# Computando estatísticas
final_stats = computeStats(df_final);

# Ordenação final
sort!(final_stats, [:AIRLINE, :Date]);

# Gera gráficos para cada companhia
g1_julia = plot_calendar_heatmap(final_stats, "AA");
g2_julia = plot_calendar_heatmap(final_stats, "DL") ;
g3_julia = plot_calendar_heatmap(final_stats, "UA");
g4_julia = plot_calendar_heatmap(final_stats, "US");
```

```
display(g1_julia)
```

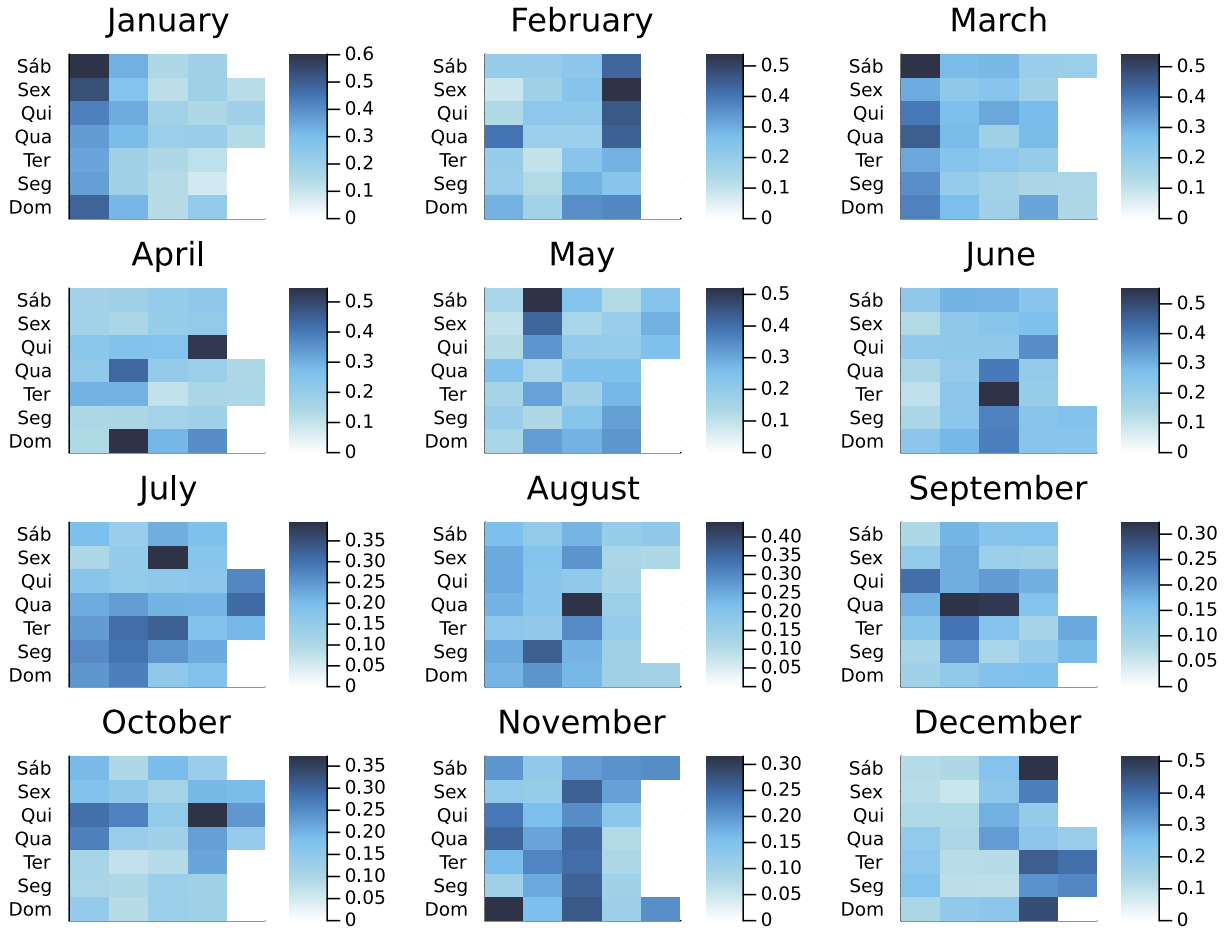

Figura: American Airlines (AA) - Julia

```
display(g2_julia)
```

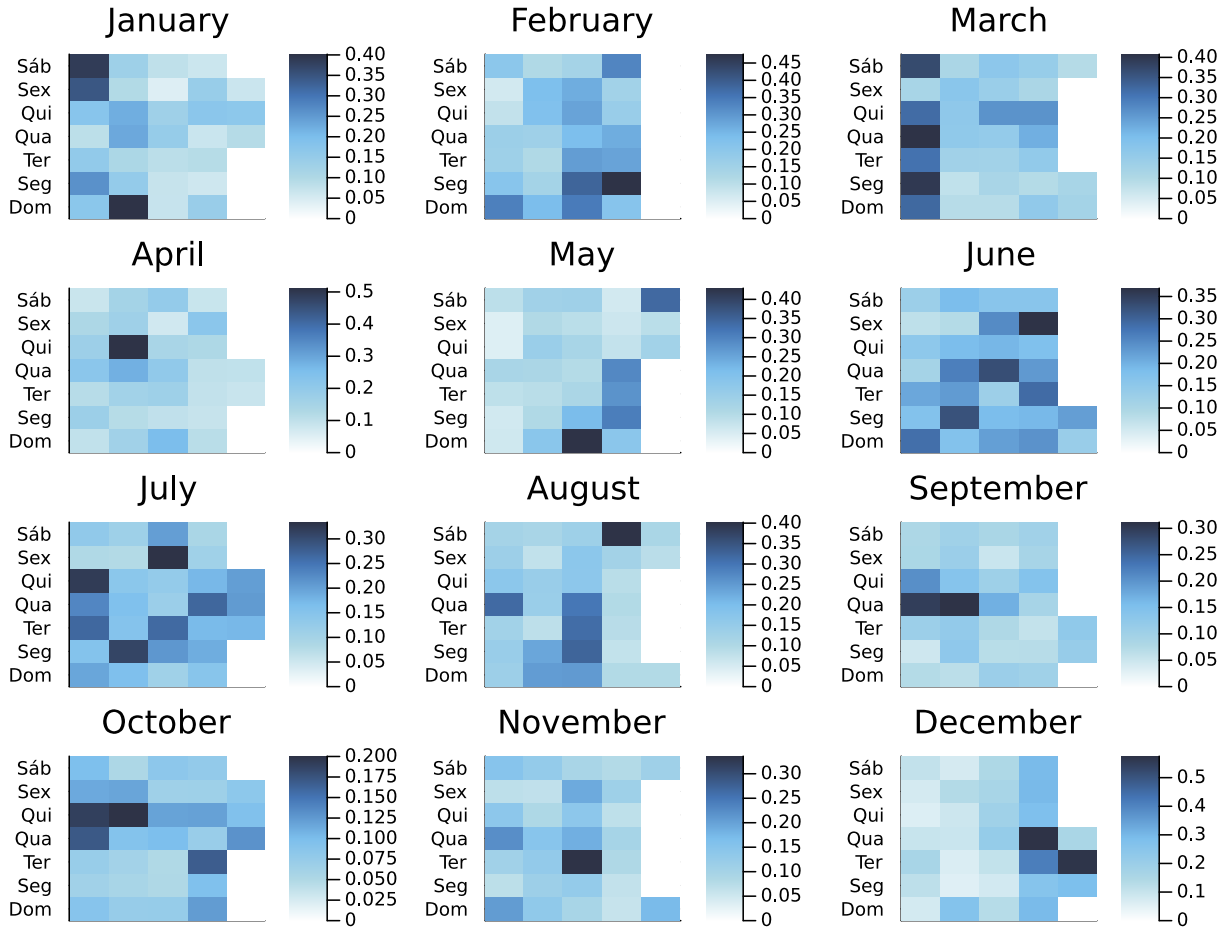

Figura: Delta Air Lines (DL) - Julia

```
display(g3_julia)
```

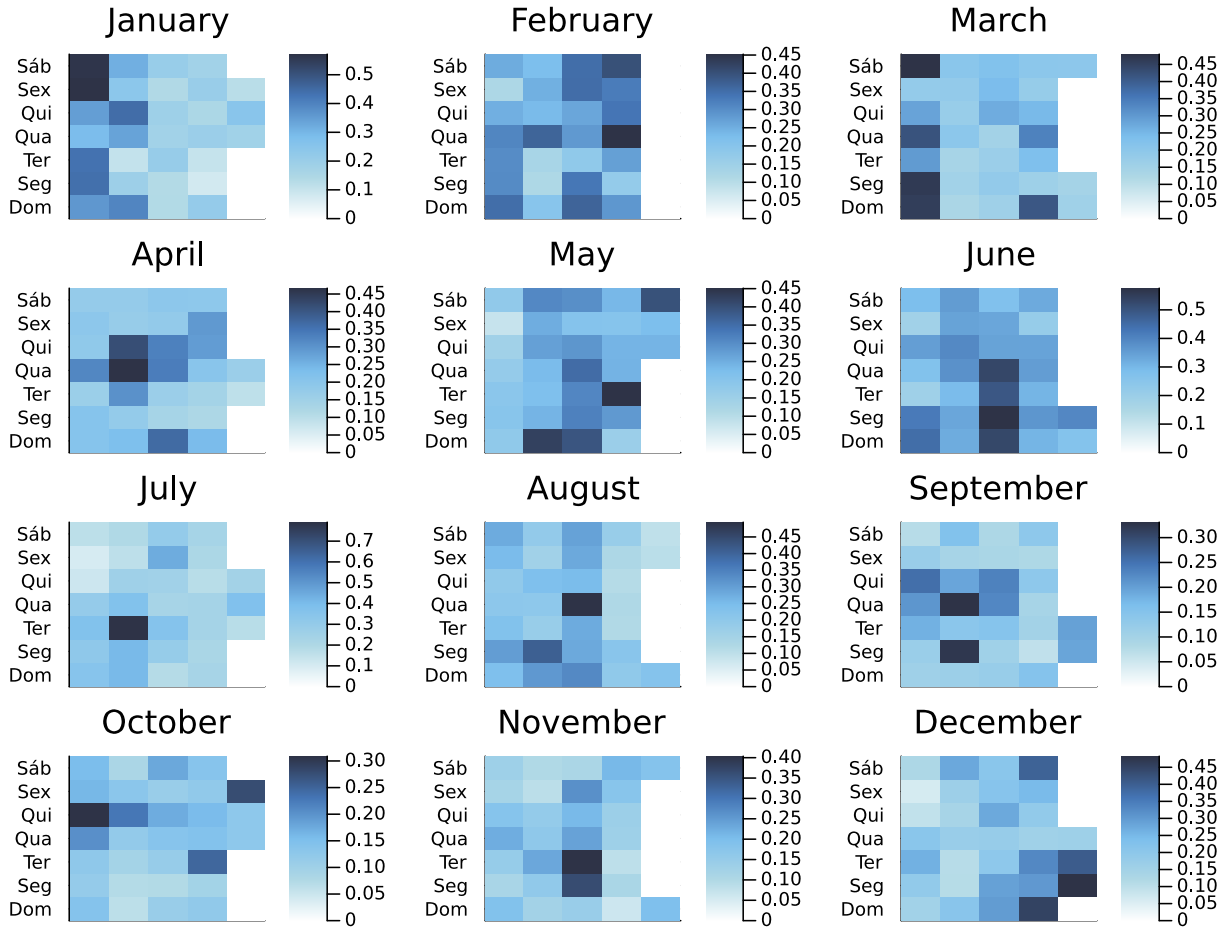

Figura: United Airlines (UA) - Julia

```
display(g4_julia)
```

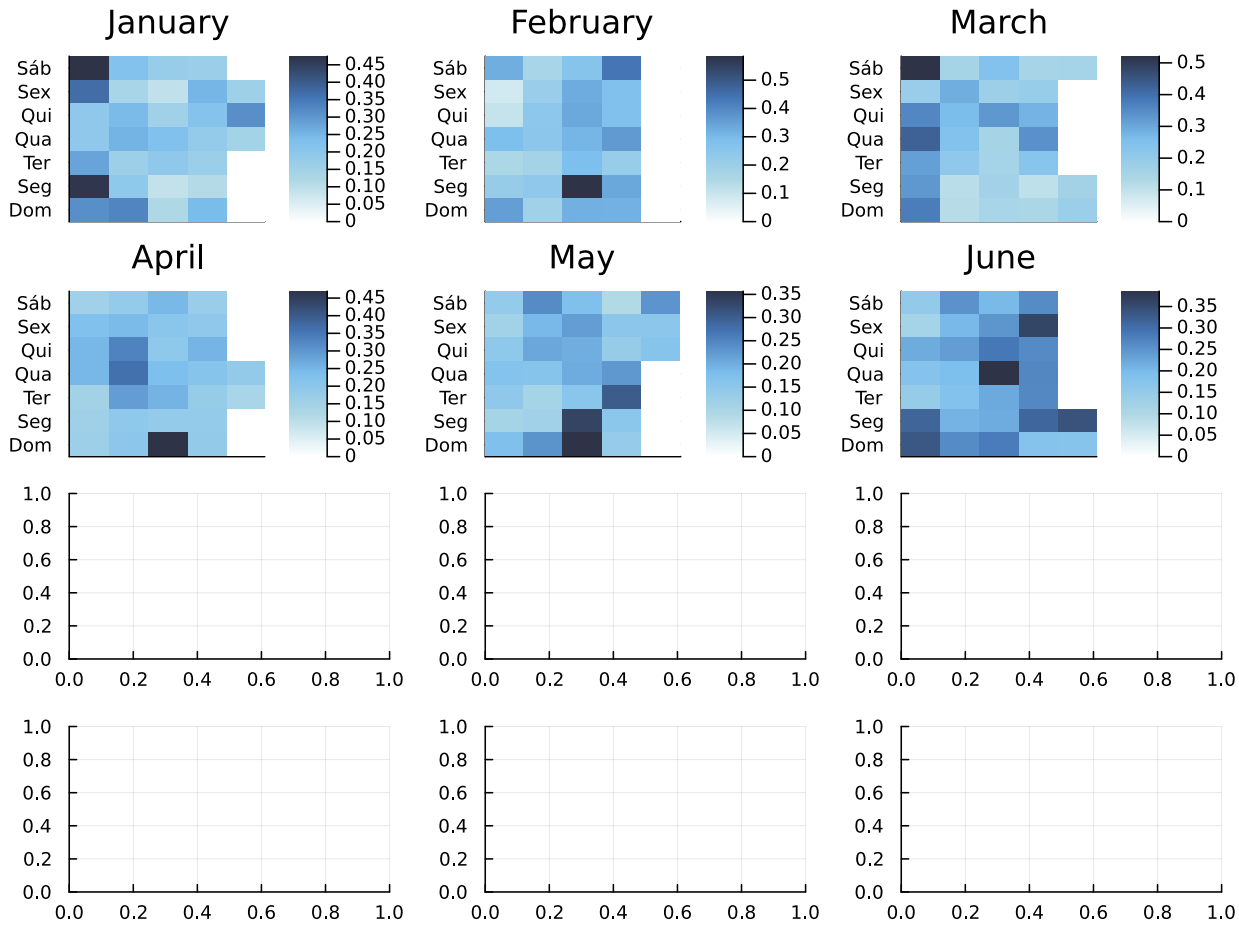

Figura: US Airways (US) - Julia

```
## Captura do tempo final
   t1 = Sys.time()
```

$$\Delta t = 85.9057590961456\ s$$

R

```r
## Captura do tempo inicial para monitoramento de performance
  t0 = Sys.time()
```

```r
  getStats = function(input, pos) {

    # Filtra os dados nas cias. de interesse e remove linhas sem valores de atraso
    input %>%
      filter(
        AIRLINE %in% c("AA", "DL", "UA", "US"),
        !is.na(ARRIVAL_DELAY)
      ) %>%

      # Agrupa dados por dia, mês e cia.
      group_by(DAY, MONTH, AIRLINE) %>%

      # Cria coluna de tipo booleano, TRUE para atraso significativo (>10 minutos)
      mutate(late = (ARRIVAL_DELAY > 10))
  }
```

```r
## Define colunas específicas para leitura eficiente dos dados CSV
  mycols = cols_only(
    DAY = 'i',           # Dia do mês (inteiro)
    MONTH = 'i',         # Mês (inteiro)
    YEAR = 'i',          # Ano (inteiro)
    AIRLINE = 'c',       # Código da Cia. (string)
    ARRIVAL_DELAY = 'i' # Tempo de atraso em minutos (inteiro)
  )

## Processa os dados em lote
  in2 = read_csv_chunked(
    file = file0,                                  # Nome do arquivo
    callback = DataFrameCallback$new(getStats), # Função a ser usada no processamento de
     ↪  cada lote.
    chunk_size = 1e5,                              # Tamanho do lote (100.000 linhas)
    col_types = mycols                             # Restrição da leitura às colunas pré
     ↪  especificadas.
  )
```

```r
  computeStats <- function(input) {
    input %>%

      # Cria uma coluna de data a partir das colunas com dados de ano, mês e dia.
      mutate(DATE = as.Date(paste(YEAR, MONTH, DAY, sep = "-"))) %>%

      # Agrupa os dados por cia. e data
      group_by(AIRLINE, DATE) %>%

      # Calcula atraso diário percentual para cada cia.
      reframe(
        Perc = sum(1 * (late)) / n()  # Converte valores booleanos para inteiros (1 ou
         ↪  0) e calcula a média da sua soma
      )
```

```
}
```

```
computeMoreStats = function(stats) {
  stats %>%

    # Seleciona
    filter(AIRLINE %in% c("AA", "DL", "UA", "US")) %>%

    # Agrupa os dados por cia.
    group_by(AIRLINE) %>%

    # Calcula o atraso percentual de cada cia.
    reframe(
      Média = round(mean(Perc) * 100, 2),
      Máx = round(max(Perc) * 100, 2)
    ) %>%
    arrange(AIRLINE)
}
```

```
## Aplica funções com computações estatísticas aos dados processados
in4 <- computeStats(in2)
```

```
## Define paleta de cores para visualização dos caledários
## Grandiente de azul a vermelho para representação da magnitude dos atrasos
pal <- scale_fill_gradient(low = "#4575b4",   # Azul (Pouco)
                           high = "#d73027")  # Vermelho (Muito)

## Base do calendário para visualização das estatísticas de atraso
baseCalendario <- function(stats, cia) {

  # Filtra os dados nas cias. de interesse
  input <- stats %>%
    filter(AIRLINE == cia)

  # Cria mapa de calor no calendário usando função do pacote ggcal
  ggcal(input$DATE, input$Perc)
}

## Gera os calendários para visualização de cada cia.
g1 <- baseCalendario(in4, "AA") +
  pal +
  ggtitle("American Airlines (AA)")

g2 <- baseCalendario(in4, "DL") +
  pal +
  ggtitle("Delta Air Lines (DL)")

g3 <- baseCalendario(in4, "UA") +
  pal +
  ggtitle("United Airlines (UA)")

g4 <- baseCalendario(in4, "US") +
  pal +
```

```
    ggtitle("US Airways (US)")
```

```
## Imprime calendários
  g1 + g2
```

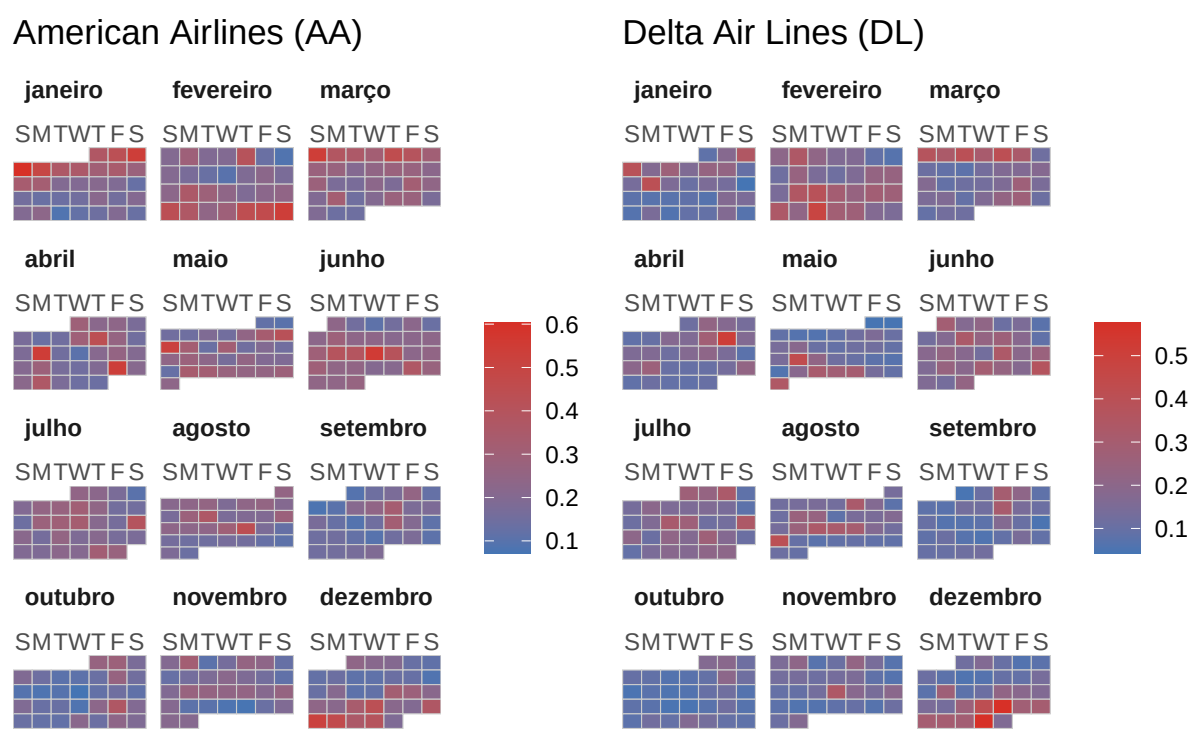


```
  g3 + g4
```

```
## Captura do tempo final
  t1 = Sys.time()
```

$$\Delta t = 48.4408531188965\ s$$

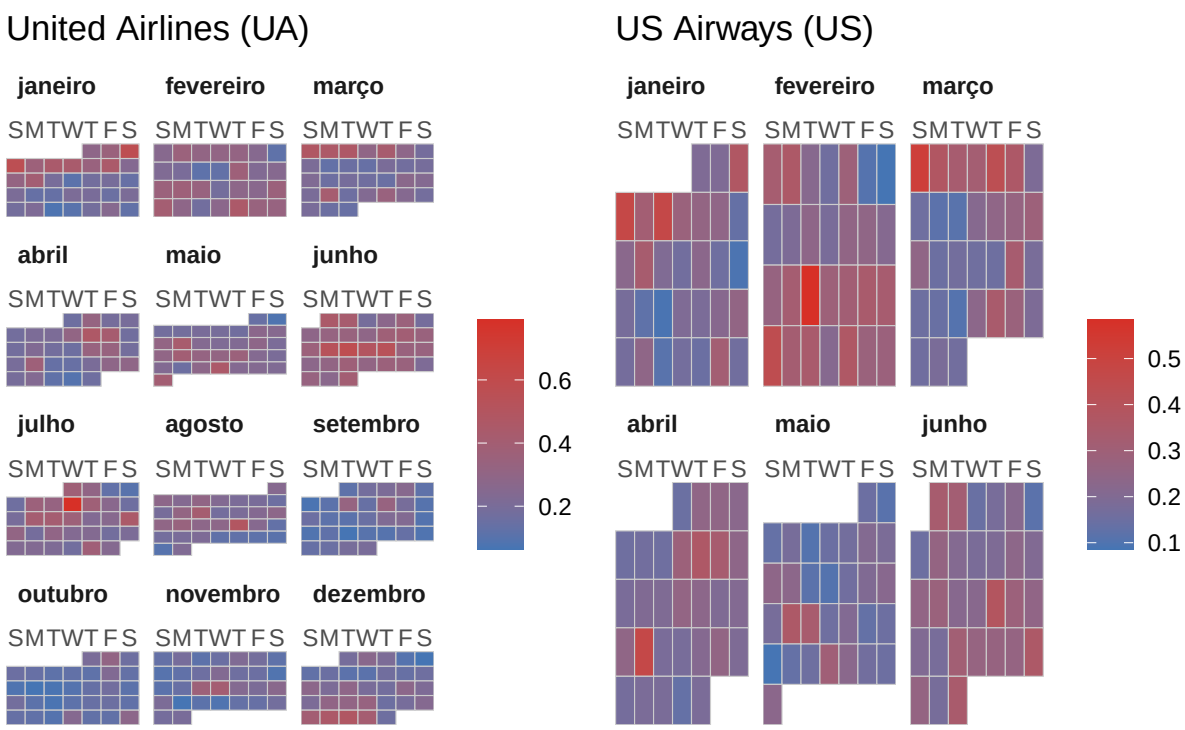

Figura 1: Mapa de calor dos vôos atrasados das Cias. aéereas AA, DL, UA e US, respectivamente

Python

```
## Inicia sessão python
   venv_python = "temp.venv"
   if(!virtualenv_exists(venv_python)){ virtualenv_create(venv_python, packages =
    ↪  c("pip","setuptools","wheel")) }

   py_install("pandas", envname = venv_python)
```

```
## Using virtual environment "temp.venv" ...
```

```
   py_install("calplot", envname = venv_python)
```

```
## Using virtual environment "temp.venv" ...
```

```
   py_install("pyarrow", envname = venv_python)
```

```
## Using virtual environment "temp.venv" ...
```

```
   use_virtualenv(venv_python)
```

```
def getStats(flight_chunk, chunk_list):

    # Seleção das cias.
    major_airlines = ['AA', 'DL', 'UA', 'US']

    # Seleciona colunas relevantes no processamento
```

```
    filtered_chunk = flight_chunk[['DAY', 'MONTH', 'YEAR', 'AIRLINE', 'ARRIVAL_DELAY']]

    # Filtra os dados nas cias.
    filtered_chunk = filtered_chunk[filtered_chunk['AIRLINE'].isin(major_airlines)]

    # Remove linhas sem valores de atraso nos vôos
    filtered_chunk = filtered_chunk.dropna(subset=['ARRIVAL_DELAY'])

    # Indentifica vôos com atraso significativos (> 10 minutos)
    filtered_chunk['late'] = filtered_chunk['ARRIVAL_DELAY'] > 10

    # Anexa lote processado a lista de resultados
    chunk_list.append(filtered_chunk)
```

```
def computeStats(flight_data):

    # Cria coluna com valores de data a partir de colunas individuais com informações de
     ↪  tempo
    flight_data['date'] = pd.to_datetime(
        flight_data[['YEAR', 'MONTH', 'DAY']],
        format="%Y-%m-%d"
    )

    # Seleciona apenas as colunas relevantes para agregação
    processed_data = flight_data[['date', 'AIRLINE', 'ARRIVAL_DELAY', 'late']]

    # Agrupa por cia. e data para calcular estatísticas de atraso
    daily_stats = processed_data.groupby(['AIRLINE', 'date']).agg(
        delayed_count=('late', 'sum'),       # Count of delayed flights
        total_flights=('AIRLINE', 'count')  # Total flights in group
    ).reset_index()

    # Cálculo do atraso percentual
    daily_stats['Perc'] = daily_stats['delayed_count'] / daily_stats['total_flights']

    # Retorna apenas colunas relevantes
    return daily_stats[['AIRLINE', 'date', 'Perc']]
```

```
def computeMoreStats(stats):
    import pandas as pd

    airlines = ['AA', 'DL', 'UA', 'US']
    resultados = []

    for airline in airlines:
        airline_data = stats[stats['AIRLINE'] == airline]

        atraso_medio = round(airline_data['Perc'].mean() * 100, 2)
        atraso_maximo = round(airline_data['Perc'].max() * 100, 2)

        resultados.append({
            'AIRLINE': airline,
            'atraso_medio': atraso_medio,
```

```
            'atraso_maximo': atraso_maximo,
        })

    return pd.DataFrame(resultados)
```

```
# Bibliotecas
import matplotlib.pyplot as plt
import calplot
import pandas as pd

## Nome do arquivo com os dados
arquivo_csv = 'flights.csv.zip'

# Define o tamanho de cada lote a ser lido
tamanho_chunck = 1e5

# Lista para armazenar os subconjuntos processados
subconjuntos_processados = []

# Cria um objeto leitor que vai iterar sobre o CD
leitor_csv = pd.read_csv(arquivo_csv, chunksize=tamanho_chunck)

# Itera sobre cada chunk do CD
for chunck in leitor_csv:
    getStats(chunck,subconjuntos_processados)

# Concatena todos os subconjuntos em um único DataFrame
df_final = pd.concat(subconjuntos_processados, ignore_index=True)

# Computa estatísticas
stats = computeStats(df_final)
```

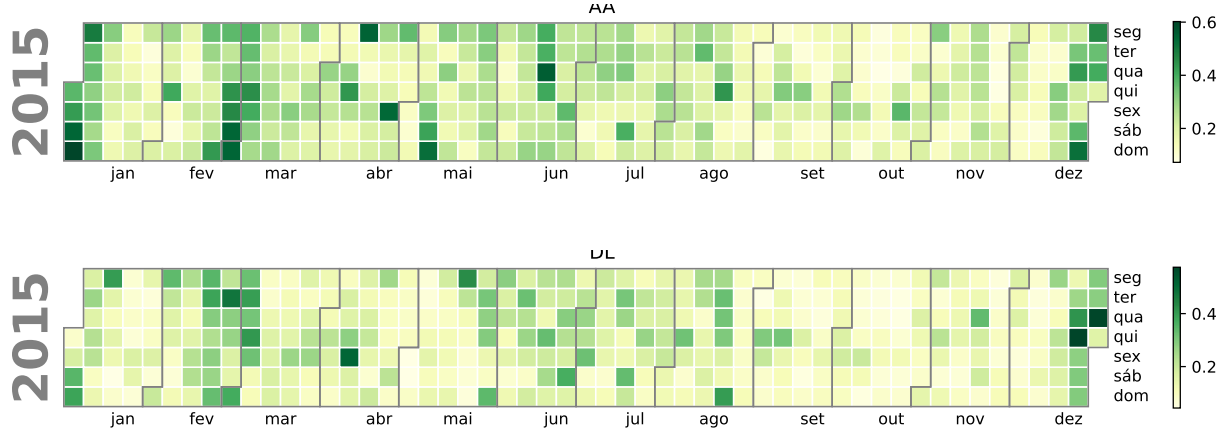

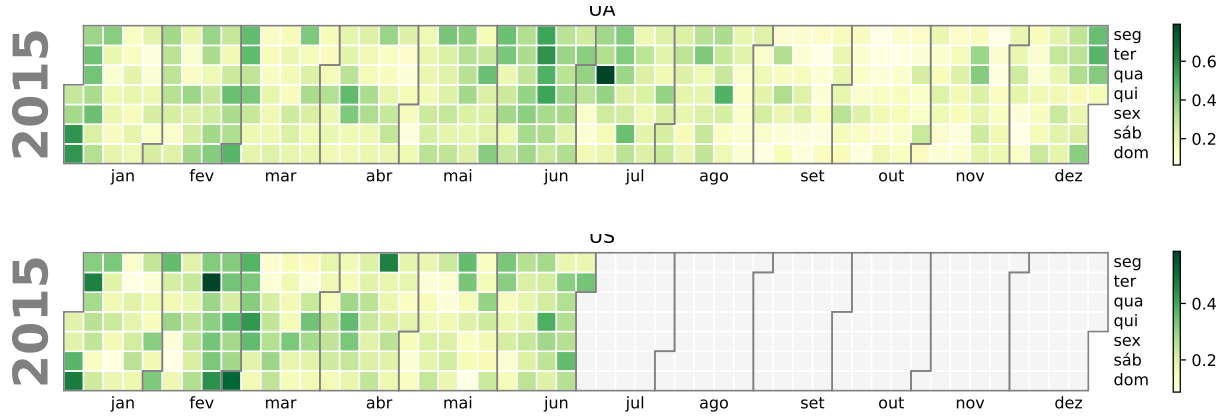

Figura 2: Mapa de calor dos vôos atrasados das Cias. aéreas AA, DL, UA e US, respectivamente. (Obtida através do Python)

```
## Encerra sessão Python (Chunk Desativada)
   virtualenv_remove(venv_python)
```

```
## Captura do tempo final
   t1 = Sys.time()
```

$$\Delta t = 91.6663510799408\ s$$

---

§ Resultados e Comparações (Julia–R)

Tabela 2: Média de vôos atrasados por Cia estudada e dia (Obtida através do Julia)

```
## Tabela kable()
   stats_julia =
 ↪  julia_eval("final_stats")
   stats_julia %>% my_kbl_foot(header =
 ↪  10)
```

AIRLINE	Date	Perc
AA	2015-01-01	0.3727339
AA	2015-01-02	0.4303714
AA	2015-01-03	0.5382456
AA	2015-01-04	0.6021433
AA	2015-01-05	0.4912869
AA	2015-01-06	0.3656934
AA	2015-01-07	0.3549075
AA	2015-01-08	0.3074753
AA	2015-01-09	0.3422724
AA	2015-01-10	0.2797147

1-10 de 1276 linhas | 3 colunas

Tabela 3: Média de vôos atrasados por Cia estudada e dia (Obtida através do R)

```
## Tabela kable()
   in4 %>% my_kbl_foot(header = 10)
```

AIRLINE	DATE	Perc
AA	2015-01-01	0.3727339
AA	2015-01-02	0.4303714
AA	2015-01-03	0.5382456
AA	2015-01-04	0.6021433
AA	2015-01-05	0.4912869
AA	2015-01-06	0.3656934
AA	2015-01-07	0.3549075
AA	2015-01-08	0.3074753
AA	2015-01-09	0.3422724
AA	2015-01-10	0.2797147

1-10 de 1276 linhas | 3 colunas

Tabela 4: Média de vôos atrasados por Cia estudada (Obtida através do Julia)

```
## Estatísticas extras
MoreStats =
 ↪  computeMoreStats(final_stats);
```

```
## Tabela kable()
   moreStats_julia =
 ↪  julia_eval("MoreStats")
   moreStats_julia %>% my_kbl()
```

AIRLINE	Atraso_Medio	Atraso_Maximo
AA	22.37	60.21
DL	16.26	57.51
UA	23.64	79.13
US	22.85	58.49

Tabela 5: Média de vôos atrasados por Cia estudada (Obtida através do R)

```
## Tabela kable()
   computeMoreStats(in4) %>% my_kbl()
```

AIRLINE	Média	Máx
AA	22.37	60.21
DL	16.26	57.51
UA	23.64	79.13
US	22.85	58.49

§ Resultados e Comparações (Julia–Python)

Tabela 2: Média de vôos atrasados por Cia estudada e dia (Obtida através do Julia)

```
## Tabela kable()
   stats_julia %>% my_kbl_foot(header =
↪  10)
```

AIRLINE	Date	Perc
AA	2015-01-01	0.3727339
AA	2015-01-02	0.4303714
AA	2015-01-03	0.5382456
AA	2015-01-04	0.6021433
AA	2015-01-05	0.4912869
AA	2015-01-06	0.3656934
AA	2015-01-07	0.3549075
AA	2015-01-08	0.3074753
AA	2015-01-09	0.3422724
AA	2015-01-10	0.2797147

1-10 de 1276 linhas | 3 colunas

Tabela 4: Média de vôos atrasados por Cia estudada (Obtida através do Julia)

```
## Tabela kable()
   moreStats_julia %>% my_kbl()
```

AIRLINE	Atraso_Medio	Atraso_Maximo
AA	22.37	60.21
DL	16.26	57.51
UA	23.64	79.13
US	22.85	58.49

Tabela 6: Média de vôos atrasados por Cia estudada e dia (Obtida através do Python)

```
## Atribui o conteúdo da variável stats
↪  no ambiente python para a variável
↪  in5 no R
## Tabela kable()
   stats_python = py$stats
   stats_python %>% my_kbl_foot(header =
↪  10)
```

AIRLINE	date	Perc
AA	2014-12-31 22:00:00	0.3727339
AA	2015-01-01 22:00:00	0.4303714
AA	2015-01-02 22:00:00	0.5382456
AA	2015-01-03 22:00:00	0.6021433
AA	2015-01-04 22:00:00	0.4912869
AA	2015-01-05 22:00:00	0.3656934
AA	2015-01-06 22:00:00	0.3549075
AA	2015-01-07 22:00:00	0.3074753
AA	2015-01-08 22:00:00	0.3422724
AA	2015-01-09 22:00:00	0.2797147

1-10 de 1276 linhas | 3 colunas

Tabela 7: Média de vôos atrasados por Cia estudada (Obtida através do Python)

```
## Estatísticas extras
MoreStats = computeMoreStats(stats)
```

```
## Tabela kable()
   moreStats_python = py$MoreStats
   moreStats_python %>% my_kbl()
```

AIRLINE	atraso_medio	atraso_maximo
AA	22.37	60.21
DL	16.26	57.51
UA	23.64	79.13
US	22.85	58.49